

Work1 proposal

任务背景：弱监督视频时序定位（Weakly-Supervised Temporal Video Grounding, WS-TVG）旨在仅使用视频与文本查询之间的匹配关系，学习从未裁剪长视频中定位与查询语义对应的目标事件片段。与全监督时序定位相比，弱监督设定不需要人工标注目标事件的起止时间，因此具有更低的标注成本和更强的实际应用价值，可服务于长视频检索、视频问答、多模态内容理解和事件级视频分析等任务。然而，由于训练阶段缺少真实时间边界，模型必须依赖视频-文本级弱标记间接推断目标片段，导致目标事件容易与人物、场景、物体和上下文动作等共现因素发生语义纠缠。

科学问题一：弱监督视频时序定位中，目标事件与上下文语义高度纠缠，模型缺乏稳定、可解释的事件判别方向。由于训练集中没有真实时间边界，候选提议只能通过文本重构质量获得间接监督。对于查询“A person opens the door”，人物、门、室内场景等信息可能在事件发生前后持续出现，模型即使没有准确覆盖“opens”这一动作，也可能依靠共现背景完成文本重构。因此，重构误差最小的候选提议不一定等价于目标事件片段，其内部可能混入背景语义；左右负提议也可能包含部分事件残余，导致正负提议之间的差异不纯净。

技术问题：单纯依赖重构误差难以区分事件本身和事件上下文。如果正提议过宽，事件特征会被背景稀释；如果正提议过窄，动作的开始或结束阶段会落入负提议中；如果多个候选提议集中到同一显著背景区域，模型将缺少覆盖真实边界的多样化候选。因此，需要在不引入人工边界标注的前提下，从弱监督训练信号中提取一个更稳定的事件级判别方向，并利用该方向约束提议特征、文本语义和候选边界。

近年来的弱监督时序定位研究表明，基于文本重构的候选排序能够提供有效语义监督，基于视频内部上下文的负样本挖掘能够增强正负区分，基于多候选投票的推理策略能够缓解单候选选择误差。然而，这些机制本质上仍依赖候选提议本身的质量。如果候选提议已经受到背景共现因素污染，后续重构和排序也会沿着错误的语义方向优化。换言之，弱监督定位不仅需要知道哪个提议能重构查询，还需要知道该提议中哪些特征真正代表目标事件。

总体来说，本方法认为弱监督定位的关键不只是生成候选区间，而是从候选区间与上下文区间的差异中提炼目标事件的判别方向。该方向应当满足三点要求：第一，与正提议中的目标动作语义一致；第二，与左右上下文背景保持区分；第三，能够跨batch稳定积累，不被单次伪标记噪声主导。

动机一：弱监督视频时序定位中，真正能够代表查询目标事件的候选片段往往只是少数，简单地将重构误差较低但包含大量背景上下文的候选提议当作可靠正样本，反而会误导模型学习到人物、场景、物体等共现信息，而不是目标事件本身的语义。另一方面，模型不应只是依赖已有的提议生成和文本重构机制去判断候选片段是否匹配查询；在正负提议边界不准确、目标事件与上下文高度纠缠的情况下，模型还应进一步学习“目标事件区别于背景上下文”的判别方向。也就是说，模型需要从伪正提议和伪负提议的特征差异中提取稳定的事件语义，并抑制由人物、场景和上下文动作带来的

冗余干扰，使模型更加关注目标事件本身。通过这种方式，模型不仅能够利用已有的候选提议和重构监督完成弱监督定位，还能够保持对目标时刻的判别能力，缓解事件语义与背景语义纠缠导致的定位边界偏移和候选排序错误问题。

方法：针对上述问题，本方法在现有重构式弱监督定位流程中引入 **Low-Rank Event Vector (LREV)** 事件解耦模块。模型首先从视频序列中生成 K 个候选提议，并使用候选提议内的视频特征重构被遮蔽的文本查询；重构误差较小的候选被视为更可能包含目标事件，其左右上下文片段则用于形成背景对比。为了提升复杂事件的覆盖能力，候选提议采用多高斯子提议形式，即一个候选可以由多个局部时间响应共同表示：

$$\mathbf{m}_k^p = \sum_{j=1}^{J_k} \pi_{k,j} \mathbf{g}_{k,j}^p.$$

其中， $\mathbf{g}_{k,j}^p \in \mathbb{R}^N$ 表示第 k 个候选内部第 j 个高斯子提议的时间掩码， $\pi_{k,j}$ 为其重要性权重，满足 $\sum_j \pi_{k,j} = 1$ 。相比单峰提议，多高斯子提议能够用多个局部响应覆盖多阶段事件，

避免为了覆盖多个关键片段而把大段背景一并纳入正提议。左右负提议 $\mathbf{m}^{n_1}$ 和 $\mathbf{m}^{n_2}$ 从正提议两侧的上下文区域中产生，用于提供事件与背景之间的对比信号。在训练过程中，正提议、左右负提议和参考提议分别得到文本重构误差 $\mathbf{L}_{\text{ce}}^p$ 、 $\mathbf{L}_{\text{ce}}^{n_1}$ 、 $\mathbf{L}_{\text{ce}}^{n_2}$ 和 L_{ce}^r 。基础训练目标要求语义相关的正提议具有更低的重构误差，并与参考提议和上下文提议保持排序间隔。这些候选区间、文本重构分数和上下文对比来源共同构成 **LREV** 的输入，使模型能够进一步分析正提议中哪些语义来自目标事件，哪些语义只是共现背景。

具体地，**LREV** 先从正提议与左右负提议的特征差异中提取事件差异方向，再通过低秩对比子空间去除背景主导方向，最终得到稳定的事件判别向量。这样，模型不仅能够利用候选重构误差获得弱监督定位信号，还能够在正负上下文对比中显式分离目标事件语义与背景共现语义。

随后，本方法定义正提议池化特征 $\mathbf{z}_k^p$ 与负提议池化特征 $\mathbf{z}_k^{n_1}$ 、 $\mathbf{z}_k^{n_2}$ 。这三个变量为本方法新增向量，分别表示第 k 个正提议、左负提议和右负提议内的视频语义特征：

$$\mathbf{z}_k^p = \sum_i \bar{m}_{k,i}^p \mathbf{h}_i, \mathbf{z}_k^{n_s} = \sum_i \bar{m}_{k,i}^{n_s} \mathbf{h}_i, \quad s \in \{1, 2\}.$$

其中， $\bar{m}$ 表示归一化后的标量掩码权重。第 k 个候选的事件差异向量定义为：

$$\Delta_k = \mathbf{z}_k^p - \frac{1}{2}(\mathbf{z}_k^{n_1} + \mathbf{z}_k^{n_2}).$$

其中， Δ_k 表示正提议相对于左右上下文的事件差异方向。该差异方向是 **LREV** 的原始估计：如果某一语义同时存在于正提议和负提议中，它会在差分中被削弱；如果某一语义主要存在于正提议中，它会在差分中被保留。因此， Δ_k 比单独的正提议特征更接近目标事件相对于背景的判别信息。为了避免只依赖硬选择 k^* ，本方法根据正提议重构误差构造软选择权重：

$$a_k = \text{softmax}_k \left(-\frac{L_{\text{ce}}^p[k]}{\tau_e} \right).$$

其中， a_k 表示第 k 个候选参与 **LREV** 子空间估计的权重， τ_e 为事件选择温度系数。相比只选取重构误差最小的单个候选，软选择能够保留多个高置信候选的信息，降低候选选择抖动对事件方向估计的影响。样本级事件差异特征和背景特征分别为：

$$\bar{\Delta} = \sum_k a_k \Delta_k,$$

$$\bar{\mathbf{z}}^n = \sum_k a_k \cdot \frac{1}{2} (\mathbf{z}_k^{n_1} + \mathbf{z}_k^{n_2}).$$

其中， $\bar{\Delta}$ 和 $\bar{\mathbf{z}}^n$ 分别表示加权后的事件差异样本和背景样本。接下来，LREV 不直接使用单个 batch 的差异向量，而是跨 batch 维护事件协方差矩阵 $\mathbf{C}_e$ 与背景协方差矩阵 $\mathbf{C}_b$ ，并采用指数滑动平均更新：

$$\mathbf{C}_c = \mathbf{C}_e - \alpha \mathbf{C}_b.$$

其中， $\mathbf{C}_c$ 表示背景抑制后的对比协方差； α 为背景抑制强度。该式是 LREV 的关键： $\mathbf{C}_e$ 强调事件差异方向， $\mathbf{C}_b$ 则刻画背景变化方向，二者相减后可以抑制人物、场景和上下文等共现背景主导的特征维度。对 $\mathbf{C}_c$ 进行特征分解：

$$\mathbf{C}_c = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top.$$

其中， r 是事件子空间秩，只保留正特征值对应的前 r 个方向，得到低秩事件子空间 $\mathbf{U}_r \in \mathbb{R}^{D_H \times r}$ 。只选择正特征值方向的原因是：正特征值表示该方向在事件差异协方差中强于背景协方差，因而更可能对应目标事件语义；负特征值方向则更可能被背景变化主导，不应进入事件子空间。第 k 个候选的 Low-Rank Event Vector 定义为：

$$\mathbf{e}_k = \mathbf{U}_r \mathbf{U}_r^\top \Delta_k.$$

其中， $\mathbf{e}_k$ 表示第 k 个候选对应的 LREV。由于 Δ_k 带有噪声，而 $\mathbf{e}_k$ 经过低秩事件子空间投影后不带有噪声，因此相比直接使用 Δ_k ，选择 $\mathbf{e}_k$ 能去除在背景协方差中占主导的方向，使事件表示更加集中于目标动作语义。

基于 LREV，本文构造事件语义分离损失。首先，正提议特征应比负提议特征更接近 LREV：

$$L_{\text{sep}} = \sum_k a_k \max(0, \beta_e - \cos(\mathbf{z}_k^p, \mathbf{e}_k) + \max_s \cos(\mathbf{z}_k^{n_s}, \mathbf{e}_k)).$$

其中， β_e 为事件分离间隔超参数。该损失使 LREV 不只是一个统计方向，而是真正参与训练：它要求正提议沿 LREV 方向具有更高相似度，负提议沿该方向具有更低相似度。其次，LREV 应与查询语义一致。令 $\mathbf{q}$ 表示由查询词特征聚合得到的文本事件锚点，则：

$$L_{\text{txt}} = \sum_k a_k (1 - \cos(\mathbf{e}_k, \mathbf{q})).$$

为了避免正提议无限扩张，进一步约束提议边界保留足够上下文。第 k 个候选的可观察上下文长度为：

$$\text{ctx}_k = \max(0, l_k^p) + \max(0, 1 - r_k^p).$$

上下文约束为：

$$L_{\text{ctx}} = \sum_k a_k \max(0, c_{\min} - \text{ctx}_k).$$

其中， $c_{\min}$ 为最小上下文长度阈值。为了避免多个候选提议塌缩到同一时间区域，引入重叠约束：

$$L_{\text{ov}} = \text{mean}_{u \neq v} \max(0, \text{IoU}(\mathbf{P}_u, \mathbf{P}_v) - o_{\max}).$$

其中， $\mathbf{P}_k = [l_k^p, r_k^p]$ 表示第 k 个预测区间向量， $o_{\max}$ 为最大允许重叠阈值。最终事件解耦损失为：

$$L_{\text{event}} = \rho(e_{\text{ep}}) (\lambda_{\text{sep}} L_{\text{sep}} + \lambda_{\text{txt}} L_{\text{txt}}) + \lambda_{\text{ctx}} L_{\text{ctx}} + \lambda_{\text{ov}} L_{\text{ov}}.$$

其中, $\rho(e_{ep})$ 为随训练轮次变化的语义项调度函数, λ_{sep} 、 λ_{txt} 、 λ_{ctx} 和 λ_{ov} 分别控制分离、文本对齐、上下文和重叠约束的权重。语义项在训练前期逐步开启, 以避免事件子空间尚未稳定时引入噪声; 边界项从训练初期生效, 以防止提议宽度过早扩张。

除上述事件解耦目标外, 模型还保留必要的候选多样性约束和推理策略。多高斯子提议之间需要避免完全重合, 不同候选之间也需要保持一定差异, 以保证前五个候选能够覆盖多种可能边界; 这些约束统一记为 L_{mix} 。推理时, 模型根据候选的文本重构误差得到候选排序, 并结合候选间的一致性进行加权投票, 最终输出 **Rank1** 结果; **Rank5** 则保留得分靠前的五个候选。该过程为 **LREV** 提供稳定的候选集合和最终排序方式, 使事件解耦方向能够作用于候选特征表达与边界可靠性。

综合上述设计, 本文最终优化目标为:

$$L = L_{rec} + \alpha_1 L_{IVC} + \alpha_2 L_{div} + L_{event} + L_{mix}.$$

其中, L_{rec} 、 L_{IVC} 、 L_{div} 和 L_{mix} 分别用于文本重构、正负排序、候选差异控制和多高斯子提议结构约束, L_{event} 则用于提取并约束目标事件相对于背景上下文的低秩判别方向。通过将 **LREV** 嵌入已有弱监督信号, 模型能够在候选生成和重构排序的基础上进一步完成事件语义解耦。

参考文献:

- [1] Gaussian-based Contrastive Proposal Learning for Weakly-Supervised Temporal Sentence Grounding. CVPR 2022.
- [2] Iterative Proposal Refinement for Weakly-Supervised Video Grounding. CVPR 2023.
- [3] Gaussian Mixture Proposals with Pull-Push Learning Scheme to Capture Diverse Events for Weakly Supervised Temporal Video Grounding. AAAI 2024.
- [4] Low-Rank Refusal Vector related video unlearning method.
- [5] Exploring Patterns Enriched in a Dataset with Contrastive Principal Component Analysis. Nature Communications 2018.