

Work1 proposal

任务背景：弱监督视频时序定位（Weakly-Supervised Temporal Video Grounding, WS-TVG）旨在仅使用视频与文本查询之间的匹配关系，学习从未裁剪长视频中定位与查询语义对应的目标事件片段。与全监督时序定位相比，弱监督设定不需要人工标注目标事件的起止时间，因此具有更低的标注成本和更强的实际应用价值，可服务于长视频检索、视频问答、多模态内容理解和事件级视频分析等任务。然而，由于训练阶段缺少真实时间边界，模型必须依赖视频-文本级弱标记间接推断目标片段，导致目标事件容易与人物、场景、物体和上下文动作等共现因素发生语义纠缠。

科学问题一：弱监督视频时序定位中，目标事件与上下文语义高度纠缠，模型缺乏稳定、可解释的事件判别方向。由于训练集中没有真实时间边界，候选提议只能通过文本重构质量获得间接监督。对于查询“A person opens the door”，人物、门、室内场景等信息可能在事件发生前后持续出现，模型即使没有准确覆盖“opens”这一动作，也可能依靠共现背景完成文本重构。因此，重构误差最小的候选提议不一定等价于目标事件片段，其内部可能混入背景语义；左右负提议也可能包含部分事件残余，导致正负提议之间的差异不纯净。

技术问题：单纯依赖重构误差难以区分事件本身和事件上下文。如果正提议过宽，事件特征会被背景稀释；如果正提议过窄，动作的开始或结束阶段会落入负提议中；如果多个候选提议集中到同一显著背景区域，模型将缺少覆盖真实边界的多样化候选。因此，需要在不引入人工边界标注的前提下，从弱监督训练信号中提取一个更稳定的事件级判别方向，并利用该方向约束提议特征、文本语义和候选边界。

近年来的弱监督时序定位研究表明，基于文本重构的候选排序能够提供有效语义监督，基于视频内部上下文的负样本挖掘能够增强正负区分，基于多候选投票的推理策略能够缓解单候选选择误差。然而，这些机制本质上仍依赖候选提议本身的质量。如果候选提议已经受到**背景共现因素污染**，后续重构和排序也会沿着错误的语义方向优化。换言之，弱监督定位不仅需要知道哪个提议能重构查询，还需要知道该提议中哪些特征真正代表目标事件。

总体来说，本方法认为弱监督定位的关键不只是生成候选区间，而是从候选区间与上下文区间的差异中提炼目标事件的判别方向。该方向应当满足三点要求：第一，与正提议中的目标动作语义一致；第二，与左右上下文背景保持区分；第三，能够跨batch稳定积累，不被单次伪标记噪声主导。

动机一：弱监督视频时序定位中，真正能够代表查询目标事件的候选片段往往只是少数，简单地将重构误差较低但包含大量背景上下文的候选提议当作可靠正样本，反而会误导模型学习到人物、场景、物体等共现信息，而不是目标事件本身的语义。另一方面，模型不应只是依赖已有的提议生成和文本重构机制去判断候选片段是否匹配查询；在正负提议边界不准确、目标事件与上下文高度纠缠的情况下，模型还应进一步学习“目标事件区别于背景上下文”的判别方向。也就是说，模型需要从伪正提议和伪负提议的特征差异中提取稳定的事件语义，并抑制由人物、场景和上下文动作带来的

冗余干扰，使模型更加关注目标事件本身。通过这种方式，模型不仅能够利用已有的候选提议和重构监督完成弱监督定位，还能够保持对目标时刻的判别能力，缓解事件语义与背景语义纠缠导致的定位边界偏移和候选排序错误问题。

方法：针对上述问题，本方法在现有重构式弱监督定位流程中引入低秩事件向量（Low-Rank Event Vector, LREV）事件解耦模块。模型首先从视频序列中生成 K 个候选提议，并使用候选提议内的视频特征重构被遮蔽的文本查询；重构误差较小的候选被视为更可能包含目标事件，其左右上下文片段则用于形成背景对比。为了提升复杂事件的覆盖能力，候选提议采用多高斯子提议形式，即一个候选可以由多个局部时间响应共同表示：

$$\mathbf{m}_k^p = \sum_{j=1}^{J_k} \pi_{k,j} \mathbf{g}_{k,j}^p.$$

其中， $\mathbf{g}_{k,j}^p \in \mathbb{R}^N$ 表示第 k 个候选内部第 j 个高斯子提议的时间掩码， $\pi_{k,j}$ 为其重要性权重，满足 $\sum_j \pi_{k,j} = 1$ 。相比单峰提议，多高斯子提议能够用多个局部响应覆盖多阶段事件，

避免为了覆盖多个关键片段而把大段背景一并纳入正提议。左右负提议 $\mathbf{m}^{n_1}$ 和 $\mathbf{m}^{n_2}$ 从正提议两侧的上下文区域中产生，用于提供事件与背景之间的对比信号。在训练过程中，正提议、左右负提议和参考提议分别得到文本重构误差 $\mathbf{L}_{cc}^p$ 、 $\mathbf{L}_{cc}^{n_1}$ 、 $\mathbf{L}_{cc}^{n_2}$ 和 L_{cc}^r 。基础训练目标要求语义相关的正提议具有更低的重构误差，并与参考提议和上下文提议保持排序间隔。这些候选区间、文本重构分数和上下文对比来源共同构成 LREV 的输入，使模型能够进一步分析正提议中哪些语义来自目标事件，哪些语义只是共现背景。

具体地，LREV 先从正提议与左右负提议的特征差异中提取事件差异方向，再通过低秩对比子空间去除背景主导方向，最终得到稳定的事件判别向量。这样，模型不仅能够利用候选重构误差获得弱监督定位信号，还能够在正负上下文对比中显式分离目标事件语义与背景共现语义。

随后，获取第 k 个正提议、左负提议和右负提议内的视频语义特征：

$$\mathbf{z}_k^p = \sum_i \bar{m}_{k,i}^p \mathbf{v}_i, \mathbf{z}_k^{n_s} = \sum_i \bar{m}_{k,i}^{n_s} \mathbf{v}_i, \quad s \in \{1, 2\}.$$

其中， $\bar{m}$ 表示归一化后的标量掩码权重， $\mathbf{v}_i$ 表示第 i 帧视频特征。第 k 个候选的事件差异向量定义为：

$$\Delta_k = \mathbf{z}_k^p - \frac{1}{2}(\mathbf{z}_k^{n_1} + \mathbf{z}_k^{n_2}).$$

其中， Δ_k 表示正提议相对于左右上下文的事件差异方向。该差异方向是 LREV 的原始估计：如果某一语义同时存在于正提议和负提议中，它会在差分中被削弱；如果某一语义主要存在于正提议中，它会在差分中被保留。因此， Δ_k 比单独的正提议特征更接近目标事件相对于背景的判别信息。为了避免只依赖硬选择 k^* ，本方法根据正提议重构误差构造软选择权重：

$$a_k = \text{softmax}_k \left(-\frac{L_{cc}^p[k]}{\tau_e} \right).$$

其中， a_k 表示第 k 个候选参与 LREV 子空间估计的权重， τ_e 为事件选择温度系数。相比只选取重构误差最小的单个候选，软选择能够保留多个高置信候选的信息，降低候选选择抖动对事件方向估计的影响。样本级事件差异特征和背景特征分别为：

$$\bar{\Delta} = \sum_k a_k \Delta_k,$$

$$\bar{\mathbf{z}}^n = \sum_k a_k \cdot \frac{1}{2} (\mathbf{z}_k^{n_1} + \mathbf{z}_k^{n_2}).$$

其中， $\bar{\Delta}$ 和 $\bar{\mathbf{z}}^n$ 分别表示加权后的事件差异样本和背景样本。接下来，LREV 不直接使用单个 batch 的差异向量，而是跨 batch 维护事件协方差矩阵 $\mathbf{C}_e$ 与背景协方差矩阵 $\mathbf{C}_b$ ，并采用指数滑动平均更新：

$$\mathbf{C}_c = \mathbf{C}_e - \alpha \mathbf{C}_b.$$

其中， $\mathbf{C}_c$ 表示背景抑制后的对比协方差； α 为背景抑制强度。该式是 LREV 的关键： $\mathbf{C}_e$ 强调事件差异方向， $\mathbf{C}_b$ 则刻画背景变化方向，二者相减后可以抑制人物、场景和上下文等共现背景主导的特征维度。对 $\mathbf{C}_c$ 进行特征分解：

$$\mathbf{C}_c = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top.$$

只保留正特征值对应的前 r 个方向，得到低秩事件子空间 $\mathbf{U}_r \in \mathbb{R}^{D_H \times r}$ ，其中， r 是事件子空间秩。只选择正特征值方向的原因是：正特征值表示该方向在事件差异协方差中强于背景协方差，因而更可能对应目标事件语义；负特征值方向则更可能被背景变化主导，不应进入事件子空间。第 k 个候选的 Low-Rank Event Vector 定义为：

$$\mathbf{e}_k = \mathbf{U}_r \mathbf{U}_r^\top \Delta_k.$$

其中， $\mathbf{e}_k$ 表示第 k 个候选对应的 LREV。由于 Δ_k 带有噪声，而 $\mathbf{e}_k$ 经过低秩事件子空间投影后不带有噪声，因此相比直接使用 Δ_k ，选择 $\mathbf{e}_k$ 能去除在背景协方差中占主导的方向，使事件表示更加集中于目标动作语义。

基于 LREV，本文构造事件语义分离损失。首先，正提议特征应比负提议特征更接近 LREV：

$$L_{\text{sep}} = \sum_k a_k \max(0, \beta_e - \cos(\mathbf{z}_k^p, \mathbf{e}_k) + \max_s \cos(\mathbf{z}_k^{n_s}, \mathbf{e}_k)).$$

其中， β_e 为事件分离间隔超参数。该损失使 LREV 不只是一个统计方向，而是真正参与训练：它要求正提议沿 LREV 方向具有更高相似度，负提议沿该方向具有更低相似度。其次，LREV 应与查询语义一致。令 $\mathbf{q}$ 表示由查询词特征聚合得到的文本事件锚点，则：

$$L_{\text{txt}} = \sum_k a_k (1 - \cos(\mathbf{e}_k, \mathbf{q})).$$

为了避免正提议无限扩张，进一步约束提议边界保留足够上下文。第 k 个候选的可观察上下文长度为：

$$\text{ctx}_k = \max(0, l_k^p) + \max(0, 1 - r_k^p).$$

上下文约束为：

$$L_{\text{ctx}} = \sum_k a_k \max(0, c_{\min} - \text{ctx}_k).$$

其中， $c_{\min}$ 为最小上下文长度阈值。为了避免多个候选提议塌缩到同一时间区域，引入重叠约束：

$$L_{\text{ov}} = \text{mean}_{u \neq v} \max(0, \text{IoU}(\mathbf{P}_u, \mathbf{P}_v) - o_{\max}).$$

其中， $\mathbf{P}_k = [l_k^p, r_k^p]$ 表示第 k 个预测区间向量， $o_{\max}$ 为最大允许重叠阈值。最终事件解耦损失为：

$$L_{\text{event}} = \rho(e_{\text{ep}}) (\lambda_{\text{sep}} L_{\text{sep}} + \lambda_{\text{txt}} L_{\text{txt}}) + \lambda_{\text{ctx}} L_{\text{ctx}} + \lambda_{\text{ov}} L_{\text{ov}}.$$

其中， $\rho(e_{\text{ep}})$ 为随训练轮次变化的语义项调度函数， λ_{sep} 、 λ_{txt} 、 λ_{ctx} 和 λ_{ov} 分别控制分离、文本对齐、上下文和重叠约束的权重。语义项在训练前期逐步开启，以避免事件子空间尚未稳定时引入噪声；边界项从训练初期生效，以防止提议宽度过早扩张。

除上述事件解耦目标外，模型还保留必要的候选多样性约束和推理策略。多高斯子提议之间需要避免完全重合，不同候选之间也需要保持一定差异，以保证前五个候选能够覆盖多种可能边界；这些约束统一记为 L_{mix} 。推理时，模型根据候选的文本重构误差得到候选排序，并结合候选间的一致性进行加权投票，最终输出 **Rank1** 结果；**Rank5** 则保留得分靠前的五个候选。该过程为 **LREV** 提供稳定的候选集合和最终排序方式，使事件解耦方向能够作用于候选特征表达与边界可靠性。

综合上述设计，本文最终优化目标为：

$$L = L_{\text{rec}} + \alpha_1 L_{\text{IVC}} + \alpha_2 L_{\text{div}} + L_{\text{event}} + L_{\text{mix}}.$$

其中， L_{rec} 、 L_{IVC} 、 L_{div} 和 L_{mix} 分别用于文本重构、正负排序、候选差异控制和多高斯子提议结构约束， L_{event} 则用于提取并约束目标事件相对于背景上下文的低秩判别方向。通过将 **LREV** 嵌入已有弱监督信号，模型能够在候选生成和重构排序的基础上进一步完成事件语义解耦。

参考文献：

任务背景：弱监督视频时序定位（Weakly-Supervised Temporal Video Grounding, WS-TVG）旨在仅使用视频与文本查询之间的匹配关系，学习从未裁剪长视频中定位与查询语义对应的目标事件片段。与全监督时序定位相比，弱监督设定不需要人工标注目标事件的起止时间，因此具有更低的标注成本和更强的实际应用价值，可服务于长视频检索、视频问答、多模态内容理解和事件级视频分析等任务。然而，由于训练阶段缺少真实时间边界，模型必须依赖视频—文本级弱标记间接推断目标片段，导致目标事件容易与人物、场景、物体和上下文动作等共现因素发生语义纠缠。

科学问题二：在没有真实时序边界监督的情况下，如何从视频内部连续变化的视觉过程和查询文本中发现与目标事件一致的局部时序结构，并利用该结构区分目标事件与相邻上下文。现有基于文本重构的方法主要根据候选片段能否恢复查询词来判断其语义相关性，但人物、物体和场景等信息可能在目标动作发生前后持续存在，使包含大量上下文的宽候选同样能够取得较低的重构误差。因此，重构质量较高的候选不一定准确覆盖目标事件，还可能跨越多个局部事件或混入与查询无关的背景片段。

技术问题：实现上述目标需要解决三个相互关联的技术难点。首先，视频聚类必须保持严格的时间连续性。一般聚类算法可能把时序上相距很远但外观相似的片段归入同一簇，破坏时序定位所需的区间结构，因此聚类过程只能合并相邻片段，并需要以稳定、确定的方式为每个视频生成可复用的事件簇边界。其次，事件簇与查询之间的匹配不能只依赖整句全局表示。查询中的谓词主要描述动作，实体主要描述参与对象，二者对事件识别和边界判断具有不同作用，需要在事件簇级别进行角色感知的跨模态交互。

现有方法对视频内部事件结构的利用也不充分。单独依赖视觉变化无法判断某一转场是否与当前查询相关，单独依赖整句语义又难以确定动作发生的局部起止位置；**将边界视为无方向的分割点**，还会忽略事件开始与事件结束对候选左右端点的不同约

束。科学问题的关键在于同时保持视频时间结构的稳定性和查询语义的选择性，使底层局部事件由视频内容决定，使事件相关性和边界方向随查询变化，并将二者统一为能够约束候选生成的细粒度时序证据。

此外，候选边界约束必须具有方向性和可微性。仅检测到某个视觉转场并不足以决定候选应位于边界左侧还是右侧；只有结合相邻事件簇的查询相关性变化，才能判断该边界对应进入目标事件还是离开目标事件。与此同时，硬边界裁剪无法稳定参与端到端训练，容易引入不可导操作和伪边界噪声。为此，需要把方向性事件边界转换为连续的跨界代价，使模型能够根据候选越界方向和越界距离获得梯度，并通过移动候选端点而不是消除边界信号来降低损失。

动机一：目标事件通常不是任意帧的集合，而是由若干时间连续、视觉语义相对一致的局部过程构成。候选提议若跨越了从查询相关事件到无关上下文的明显转场，即使其文本重构误差较低，也不应被视为边界可靠的候选。相反，当相邻事件簇之间同时存在显著视觉变化和查询相关性变化时，该位置能够提供比全局重构误差更细粒度的边界证据。将这种证据加入候选学习，可以抑制候选依靠人物、物体和场景等持续性线索无限扩张。

另一方面，事件开始边界和结束边界具有不对称性。当相关性从低到高时，边界更可能表示目标事件开始，候选左端点不应越过该位置继续向左扩张；当相关性从高到低时，边界更可能表示目标事件结束，候选右端点不应越过该位置继续向右扩张。因此，本方法不把事件边界简化为无方向的分割点，而是构造两类方向性屏障，并根据候选覆盖屏障的程度和端点越界距离施加连续约束。为了避免新增结构在训练初期破坏已有候选生成能力，事件提示通过零初始化残差适配器注入，使模型从恒等映射开始逐步学习视频结构带来的修正。

方法：针对上述问题，本方法在现有重构式弱监督定位流程中引入查询条件一致事件簇（Query-Conditioned Coherent Event Clusters, QCEC）。给定弱监督视频-查询对，模型从视频序列中生成 K 个候选提议，并使用候选提议内的视频特征重构被掩码的文本查询。为覆盖具有多个局部阶段的复杂事件，第 k 个正提议采用多高斯子提议表示：

$$m_k^p = \sum_{j=1}^{J_k} \pi_{k,j} g_{k,j}^p.$$

其中， $g_{k,j}^p \in \mathbb{R}^N$ 是第 k 个候选内部第 j 个高斯子提议的时序掩码， $\pi_{k,j}$ 是该子提议的重要性权重， J_k 是第 k 个候选包含的高斯子提议数， N 是视频序列的采样长度，并且满足 $\sum_j \pi_{k,j} = 1$ 。左右负提议 m^{n_1} 和 m^{n_2} 从正提议两侧的上下文区域中产生。正提议、左右负提议和参考提议的文本重构误差分别记为 $\mathcal{L}_{ce}^p$ 、 $L_{ce}^{n_1}$ 、 $L_{ce}^{n_2}$ 和 L_{ce}^r 。

仅依赖重构误差时，模型容易把持续出现的人物、物体和场景当作定位依据，同时忽略动作发生处的局部视觉突变。QCEC 将视频预先划分为一组时序连续、视觉一致的事件簇，再利用查询谓词、实体和整句语义估计每个事件簇与目标事件的相关性。相邻事件簇之间的视觉变化与查询相关性变化共同形成方向性边界：当语义从相关变为不相关时，该边界阻止候选右端点继续向右扩张；当语义从不相关变为相关时，该边界阻止候选左端点继续向左扩张。由此，候选生成同时利用全局重构监督和局部事件结构，降低候选跨越无关事件边界的概率。

给定采样后的视频特征序列 $\{\mathbf{h}_i\}_{i=1}^N$ ，首先对每个 $\mathbf{h}_i$ 进行 L_2 归一化。初始化时，每个采样位置单独构成一个事件簇；随后只允许时间上相邻的两个事件簇合并。对于相邻事件簇 $\mathcal{C}_u$ 和 $\mathcal{C}_v$ ，其**最小方差合并代价**定义为：

$$d_w(C_u, C_v) = \frac{|C_u| |C_v|}{|C_u| + |C_v|} \|\mu_u - \mu_v\|_2^2.$$

其中, C_u 和 C_v 是时间上相邻的两个事件簇, $|C_u|$ 和 $|C_v|$ 是各自包含的采样位置数, μ_u 和 μ_v 是各自的平均视觉特征, $d_w(\cdot)$ 是合并两个相邻事件簇造成的类内方差增量。每一步选择 $d_w(\cdot)$ 最小的相邻簇对进行合并, 直至得到 M 个事件簇。第 m 个事件簇对应归一化半开区间:

$$C_m = [b_m^l, b_m^r), \quad m \in \{1, \dots, M\}.$$

其中, b_m^l 是第 m 个事件簇的归一化左边界, b_m^r 是其归一化右边界, M 是预设事件簇数。该聚类过程只使用视频特征, 每个视频仅离线计算一次, 不使用查询文本、候选提议或真实时间边界; 因此, 同一视频对应的不同查询共享相同的底层时间结构。

普通均值池化会削弱簇边缘处的变化信息, 而候选边界恰好更依赖这些局部变化。对于属于 C_m 的第 i 个采样位置, 先定义其簇内相对位置:

$$\xi_i = \begin{cases} \frac{i - s_m}{e_m - s_m - 1}, & e_m - s_m > 1, \\ \frac{1}{2}, & e_m - s_m = 1, \end{cases}$$

其中, s_m 是事件簇 C_m 在离散采样序列中的起始索引, e_m 是其半开结束索引, $\xi_i \in [0, 1]$ 是采样位置 i 在簇内的归一化坐标。边界增强权重及事件簇表示定义为:

$$\mathbf{v}_m = \frac{\sum_{i \in C_m} \omega_i \mathbf{h}_i}{\sum_{i \in C_m} \omega_i}, \quad \omega_i = 1 + \gamma_b \left(2 \left| \xi_i - \frac{1}{2} \right| \right)^{p_b},$$

其中, ω_i 是第 i 个采样位置的池化权重, $\gamma_b \geq 0$ 是簇边缘增强强度, $p_b > 0$ 是边缘响应的形状系数, $\mathbf{v}_m$ 是第 m 个事件簇的边界增强视觉表示。该设计提高簇首尾采样位置的贡献, 同时保留簇内部的整体语义。

将查询词划分为谓词、实体和整句三个语义角色, 并分别对对应词特征进行平均池化:

$$\mathbf{q}_a = \frac{\sum_{t=1}^W R_{a,t} \mathbf{x}_t}{\sum_{t=1}^W R_{a,t}}, \quad a \in \{\text{pre}, \text{ent}, \text{sen}\}.$$

其中, $\mathbf{x}_t$ 是第 t 个查询词的上下文化特征, W 是有效查询词数, $R_{a,t} \in \{0, 1\}$ 是词 t 是否属于角色 a 的掩码, $\mathbf{q}_{\text{pre}}$ 是谓词语义表征, $\mathbf{q}_{\text{ent}}$ 是实体语义表征, $\mathbf{q}_{\text{sen}}$ 是整句语义表征。谓词角色包含动词及其相邻副词, 实体角色包含名词及其相邻形容词。若谓词或实体角色没有可用词, 则使用全部有效查询词进行池化。整句语义表示记为文本事件锚点 $\mathbf{q} = \mathbf{q}_{\text{sen}}$ 。为使三种角色在共享特征空间中仍保持可区分性, 在角色表示中加入可学习角色嵌入:

$$\mathbf{q}_a = \mathbf{q}_a + \mathbf{e}_a.$$

其中, $\mathbf{e}_a$ 是角色 a 的可学习嵌入, $\mathbf{q}_a$ 是加入角色身份后的查询表示。

每个事件簇根据自身视觉内容自适应选择三种查询角色:

$$\mathbf{A}_{m,a} = \text{softmax}_a \left(\frac{(\mathbf{W}_c \mathbf{v}_m)^\top (\mathbf{W}_q \mathbf{q}_a)}{\sqrt{D_a}} \right), \quad \tilde{\mathbf{q}}_m = \sum_a \mathbf{A}_{m,a} \mathbf{q}_a.$$

其中， $\mathbf{W}_c$ 是事件簇视觉投影矩阵， $\mathbf{W}_q$ 是查询角色投影矩阵， D_a 是注意力空间维度， $\mathbf{A}_{m,a}$ 是事件簇 m 对角色 a 的注意力权重， $\tilde{\mathbf{q}}_m$ 是与事件簇 m 对齐的查询语义。随后进行残差式跨模态融合：

$$\tilde{\mathbf{v}}_m = \text{LN}(\mathbf{v}_m + \text{FFN}([\mathbf{v}_m; \tilde{\mathbf{q}}_m; \mathbf{v}_m \odot \tilde{\mathbf{q}}_m])).$$

其中， $[\cdot; \cdot]$ 是向量拼接操作， $\odot$ 是逐元素乘法， $\text{FFN}(\cdot)$ 是前馈融合网络， $\text{LN}(\cdot)$ 是层归一化， $\tilde{\mathbf{v}}_m$ 是查询增强后的第 m 个事件簇表示。

使用整句语义估计每个事件簇与目标事件的匹配程度：

$$\chi_m = \sigma \left(\frac{\cos(\mathbf{W}_v \tilde{\mathbf{v}}_m, \mathbf{W}_s \mathbf{q}_{\text{sen}}) - \mathbf{b}_\chi}{\tau_\chi} \right).$$

其中， $\mathbf{W}_v$ 是查询增强事件簇的投影矩阵， $\mathbf{W}_s$ 是整句查询的投影矩阵， $\mathbf{b}_\chi$ 是可学习相关性偏置， τ_χ 是相关性温度系数， $\sigma(\cdot)$ 是 Sigmoid 函数， $\chi_m \in [0,1]$ 是第 m 个事件簇的查询相关性。较大的 χ_m 表明该事件簇更可能包含查询描述的目标事件。

相邻事件簇之间的视觉转场强度定义为：

$$\psi_m = \sigma \left(\frac{d'_m - \delta_t}{\tau_t} \right), \quad d'_m = 1 - \cos(\mathbf{v}_m, \mathbf{v}_{m+1}), \quad m \in \{1, \dots, M-1\}.$$

其中， d'_m 是事件簇 m 与事件簇 $m+1$ 之间的余弦距离， δ_t 是视觉转场阈值， $\tau_t > 0$ 是转场温度系数， $\psi_m \in [0,1]$ 是两个相邻事件簇之间的视觉转场强度。计算 ψ_m 时停止其梯度，避免模型通过人为改变簇表示来削弱固定的视频时间结构。

视觉变化本身不能判断边界属于目标事件的哪一侧，因此进一步结合相邻事件簇的查询相关性变化。内部边界的左、右端点提示定义为：

$$\eta_m^L = \psi_{m-1} \max(0, \chi_m - \chi_{m-1} - \delta_\chi), \quad m \in \{2, \dots, M\},$$

$$\eta_m^R = \psi_m \max(0, \chi_m - \chi_{m+1} - \delta_\chi), \quad m \in \{1, \dots, M-1\}.$$

其中， η_m^L 是事件簇 m 的左边界提示， η_m^R 是事件簇 m 的右边界提示， $\delta_\chi \geq 0$ 是相邻事件簇相关性变化的最小间隔。视频首端和末端分别使用 $\eta_1^L = \chi_1$ 与 $\eta_M^R = \chi_M$ ，使全局提示能够覆盖靠近视频边缘的事件。对于事件簇 m 与事件簇 $m+1$ 之间的位置 $t_m = b_m^r = b_{m+1}^l$ ，构造两个具有方向的事件屏障：

$$B_m^{\text{LR}} = \psi_m \max(0, \chi_m - \chi_{m+1} - \delta_\chi),$$

$$B_m^{\text{RL}} = \psi_m \max(0, \chi_{m+1} - \chi_m - \delta_\chi).$$

其中， t_m 是第 m 个内部簇边界的归一化时间位置， B_m^{LR} 是“左侧相关、右侧不相关”的方向性屏障强度， B_m^{RL} 是“左侧不相关、右侧相关”的方向性屏障强度。前者约束候选右端点越过目标事件的结束边界，后者约束候选左端点越过目标事件的开始边界。只有视觉转场明显且查询相关性按对应方向发生变化时，屏障才具有较大强度。

分别根据事件簇相关性、左边界提示和右边界提示对查询增强事件簇进行加权池化：

$$\mathbf{v}^{\text{rel}} = \frac{\sum_m \chi_m \tilde{\mathbf{v}}_m}{\sum_m \chi_m}, \quad \mathbf{v}^L = \frac{\sum_m \eta_m^L \tilde{\mathbf{v}}_m}{\sum_m \eta_m^L}, \quad \mathbf{v}^R = \frac{\sum_m \eta_m^R \tilde{\mathbf{v}}_m}{\sum_m \eta_m^R}.$$

其中， $\mathbf{v}^{\text{rel}}$ 是查询相关事件的全局语义特征， $\mathbf{v}^L$ 是目标事件左边界特征， $\mathbf{v}^R$ 是目标事件右边界特征。当左边界或右边界提示的总权重为零时，使用 $\mathbf{v}^{\text{rel}}$ 作为对应特征，避免无效除法并保持稳定梯度。

查询条件下的软边界位置定义为：

$$\hat{l} = \frac{\sum_m \eta_m^L b_m^l}{\sum_m \eta_m^L}, \quad \hat{r} = \frac{\sum_m \eta_m^R b_m^r}{\sum_m \eta_m^R}.$$

其中， $\hat{l}$ 是由全部左边界提示聚合得到的软起点， $\hat{r}$ 是由全部右边界提示聚合得到的软终点。当对应提示为空时，使用相关性最高事件簇的左边界或右边界作为回退值。

将事件语义、左右边界语义和软边界位置压缩为全局事件结构提示：

$$\mathbf{g} = \mathbf{W}_g[\mathbf{v}^{\text{rel}}; \mathbf{v}^L; \mathbf{v}^R; \hat{l}; \hat{r}].$$

其中， $\mathbf{W}_g$ 是全局提示投影矩阵， $\mathbf{g}$ 是查询条件下的全局事件结构提示。该提示通过零初始化输出层的残差适配器注入候选生成特征：

$$\tilde{\mathbf{h}}_g = \mathbf{h}_g + \mathbf{W}_o \text{GELU}(\mathbf{W}_i[\mathbf{h}_g; \mathbf{g}])$$

其中， $\mathbf{h}_g$ 是候选生成器原始的全局隐状态， $\mathbf{W}_i$ 是适配器输入投影矩阵， $\mathbf{W}_o$ 是零初始化的适配器输出投影矩阵， $\tilde{\mathbf{h}}_g$ 是融合事件结构后的候选生成特征。零初始化使训练开始时 $\tilde{\mathbf{h}}_g = \mathbf{h}_g$ ，随后再逐步学习事件结构对候选中心、宽度和多高斯子提议参数的修正。

为保留多个可能的事件区域，可选地选取相关性最高的 K 个事件簇作为候选槽位。第 k 个槽位的粗中心和粗宽度定义为：

$$\bar{c}_k = \frac{b_{m_k}^l + b_{m_k}^r}{2}, \quad \bar{w}_k = b_{m_k}^r - b_{m_k}^l.$$

其中， m_k 是相关性排序后分配给第 k 个候选的事件簇索引， $\bar{c}_k$ 是该槽位的粗时序中心， $\bar{w}_k$ 是该槽位的粗时间宽度。槽位特征与 $(\bar{c}_k, \bar{w}_k)$ 经过零初始化预测头后，只作为候选参数预测的加性偏置，不直接替换由重构监督学习得到的候选提议。

第 k 个预测区间为 $P_k = [l_k^p, r_k^p]$ 。为了判断该区间是否跨越内部簇边界 t_m ，使用可微分跨界门控：

$$G_{k,m} = \sigma\left(\frac{r_k^p - t_m}{\tau_c}\right) \sigma\left(\frac{t_m - l_k^p}{\tau_c}\right).$$

其中， $G_{k,m} \in [0,1]$ 是候选 P_k 覆盖边界 t_m 的软指示量， $\tau_c > 0$ 是跨界门控温度系数。当 $l_k^p < t_m < r_k^p$ 时， $G_{k,m}$ 接近1；当边界位于候选之外时， $G_{k,m}$ 接近0。

候选相对边界的左右越界距离定义为：

$$o_{k,m}^R = \max(0, r_k^p - t_m), \quad o_{k,m}^L = \max(0, t_m - l_k^p).$$

其中， $o_{k,m}^R$ 是候选右端点越过边界 t_m 的距离， $o_{k,m}^L$ 是候选左端点越过边界 t_m 的距离。方向性跨界损失定义为：

$$\mathcal{L}_{\text{cross}} = \frac{1}{K \sum_m I_m} \sum_{k=1}^K \sum_{m=1}^{M-1} I_m G_{k,m} (B_m^{\text{LR}} o_{k,m}^R + B_m^{\text{RL}} o_{k,m}^L).$$

其中, $I_m \in \{0,1\}$ 是内部簇边界 t_m 是否有效的掩码, $\mathcal{L}_{\text{cross}}$ 是所有候选在有效方向性屏障上的平均跨界代价。训练时可停止 B_m^{LR} 和 B_m^{RL} 的梯度, 使模型主要通过移动候选边界来降低跨界损失, 而不是通过压平事件簇相关性来消除屏障。QCEC 约束写为:

$$\mathcal{L}_{\text{qcec}} = \lambda_{\text{cross}} \mathcal{L}_{\text{cross}}.$$

其中, λ_{cross} 是方向性跨界损失的权重, $\mathcal{L}_{\text{qcec}}$ 是查询条件事件结构带来的附加训练目标。

训练得到候选后, 可在推理阶段将端点吸附到附近的高置信事件簇边界。对候选左端点 l_k^p , 在半径 ε_s 内寻找满足 $\eta_m^L \geq \theta_b$ 且 $\chi_m \geq \theta_r$ 的最近 b_m^L ; 对候选右端点 r_k^p , 在同一半径内寻找满足 $\eta_m^R \geq \theta_b$ 且 $\chi_m \geq \theta_r$ 的最近 b_m^R 。若吸附后的区间宽度不小于 $w_{\min}$, 则接受该边界, 否则保留原候选端点。

其中, ε_s 是按有效视频长度归一化的最大吸附半径, θ_b 是边界提示置信度阈值, θ_r 是事件簇相关性阈值, $w_{\min}$ 是允许的最小候选宽度。视频的归一化边缘 0 和 1 使用独立且更严格的置信度阈值, 以避免候选被低成本地吸附到整个视频范围。边界吸附只改变推理输出, 不参与训练反向传播; 关闭该策略时, 直接使用原始 P_k 进行排序和评测。在训练阶段, 文本重构、正负排序、候选差异控制和多高斯子提议结构约束共同构成基础训练目标, 完整优化目标为:

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \alpha_1 \mathcal{L}_{\text{IVC}} + \alpha_2 \mathcal{L}_{\text{div}} + \mathcal{L}_{\text{mix}} + \mathcal{L}_{\text{qcec}}.$$

其中, $\mathcal{L}_{\text{rec}}$ 是文本重构损失, $\mathcal{L}_{\text{IVC}}$ 是正提议与参考提议、左右负提议之间的排序损失, $\mathcal{L}_{\text{div}}$ 是候选差异控制损失, $\mathcal{L}_{\text{mix}}$ 是多高斯子提议的聚合与多样性约束, α_1 是正负排序损失权重, α_2 是候选差异控制损失权重, $\mathcal{L}_{\text{qcec}}$ 是方向性事件边界约束。

推理时, 模型根据候选的文本重构误差得到候选排序, 并结合候选间一致性进行加权投票, 最终输出 **Rank1** 结果; **Rank5** 保留得分靠前的五个候选。若启用边界吸附, 则先对候选端点执行吸附, 再使用相同排序策略。由此, QCEC 不改变弱监督训练设定, 也不依赖人工时间边界, 而是通过视频内部的连续视觉结构和查询条件语义, 为候选生成与边界学习提供细粒度事件约束。